

Pontifícia Universidade Católica de Minas Gerais
Curso de Ciência da Computação
Trabalho de Conclusão de Curso

Análise de domínios no aprendizado por transferência para classificação de nódulos tireoidianos

Karine Mendes Tavares

Alexei M. C. Machado
Orientador

Sumário

- Introdução
- Materiais e métodos
- Resultados e Discussão
- Considerações finais

Introdução

Contexto

- Tireoide é uma glândula que regula o metabolismo do corpo humano
- Nódulos são problemas comuns
- A incidência de nódulos palpáveis de tireoide na população adulta é de cerca de 67% e 10% deles podem ser malignos

Introdução

Contexto

- Ultrassonografia para detectar e diagnosticar
 - São menos invasivas e apresentam o melhor custo-benefício
 - Alto nível de expertise para interpretá-las

Introdução

Contexto

- Classificação dos nódulos é um desafio para os médicos
- Sistema de classificação
 - TI-RADS, Kwak et al. 2011
 - 1, 2, 3, 4a, 4b, 4c, 5

Introdução

Motivação

- Sistemas de diagnóstico assistido por computador (CAD) e aprendizado profundo
 - Redes Neurais Convolucionais (CNNs)
- Tamanho da base de dados interfere na qualidade de aprendizado
 - Imagenet
 - RadImageNet

Introdução


Objetivo

- Avaliação da adaptação de domínio no aprendizado por transferência na classificação de nódulos tireoidianos
 - Pesos ImageNet e RadImageNet

Introdução

Objetivo


- TI-RADS categoria 4



4a



4b



4c

Fonte: Pedraza et al.

Materiais e Métodos

1. Base de dados
2. Seleção das imagens
3. Modelos de treinamento e Arquitetura
4. Métricas de Avaliação

Materiais e métodos

Base de dados

- DDTI (*Digital Database Thyroid Image*)
 - Disponibilizada pela Universidade Nacional da Colômbia
- 480 imagens de ultrassom

TI-RADS	Nº Imagens
2	42
3	19
4a	96
4b	79
4c	68
5	45

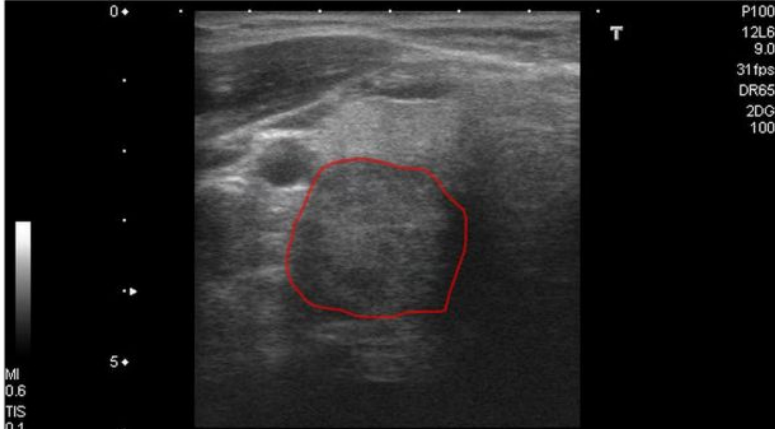
Materiais e métodos

Base de dados

← → ↻ 168.176.61.6/tiroides/public/mark.php?caso=47 ☆ ☰

Return to list cases

⏮



Age:46 | Sex: M

Nodule composition: solid

Echogenicity: isoechogenicity

Shape: ovoide

Margins: well defined smooth

Calcifications: non

TIRADS: 3

BETHESDA:
BETHESDA IV , SUSPICIOUS FOR MALIGNANCY

Fonte: Pedraza et al.

Materiais e métodos

Seleção das Imagens

- Seleção das imagens TI-RADS 4a, 4b e 4c
- Separação estratificada de 10 dobras
- Mesmo paciente sempre no mesmo conjunto

Materiais e métodos

Segmentação

- Leitura do xml, recorte e fundo verde para cada imagem



TIRADS-4b


```
<case><number>45</number><age>74</age><sex>F
</sex><composition>solid</composition><echogenicity>
hypoechogenicity</echogenicity><margins>well defined
</margins><calcifications>macrocalcifications
</calcifications><tirads>4b
</tirads><reportbacaf></reportbacaf><reporteco></reporteco><mar
k><image>1</image><svg>[{"points": [{"x": 305, "y": 84},
{"x": 299, "y": 85}, {"x": 291, "y": 88}, {"x": 286, "y":
90}, {"x": 264, "y": 95}, {"x": 259, "y": 101}, {"x": 255,
"y": 106}, {"x": 251, "y": 110}, {"x": 248, "y": 118}, {"x":
245, "y": 125}, {"x": 245, "y": 132}, {"x": 243, "y": 153},
{"x": 256, "y": 170}, {"x": 261, "y": 175}, {"x": 267, "y":
180}, {"x": 281, "y": 186}, {"x": 288, "y": 187}, {"x": 296,
"y": 187}, {"x": 304, "y": 187}, {"x": 306, "y": 187}, {"x":
307, "y": 188}, {"x": 321, "y": 188}, {"x": 333, "y": 186},
{"x": 340, "y": 180}, {"x": 347, "y": 175}, {"x": 354, "y":
169}, {"x": 359, "y": 164}, {"x": 363, "y": 155}, {"x": 365,
"y": 148}, {"x": 367, "y": 139}, {"x": 367, "y": 134}, {"x":
368, "y": 126}, {"x": 363, "y": 117}, {"x": 359, "y": 115},
{"x": 355, "y": 109}, {"x": 350, "y": 104}, {"x": 347, "y":
99}, {"x": 346, "y": 97}, {"x": 341, "y": 93}, {"x": 338,
"y": 92}, {"x": 332, "y": 91}, {"x": 325, "y": 89}, {"x":
318, "y": 86}, {"x": 308, "y": 85}, {"x": 306, "y": 85}],
"annotation": {}, "regionType": "freehand"}]
</svg></mark></case>
```

45.xml

Materiais e métodos


Segmentação

- Resultado final



Materiais e métodos

Aumento de dados e pré-processamento



Materiais e métodos


Modelos pré-treinados e arquiteturas

- ImageNet
- RadImageNet
 - DenseNet-121, InceptionResNetV2, InceptionV3 e ResNet50

Materiais e métodos

Arquiteturas

- DenseNet-121
 - 121 camadas
 - 7381 conexões

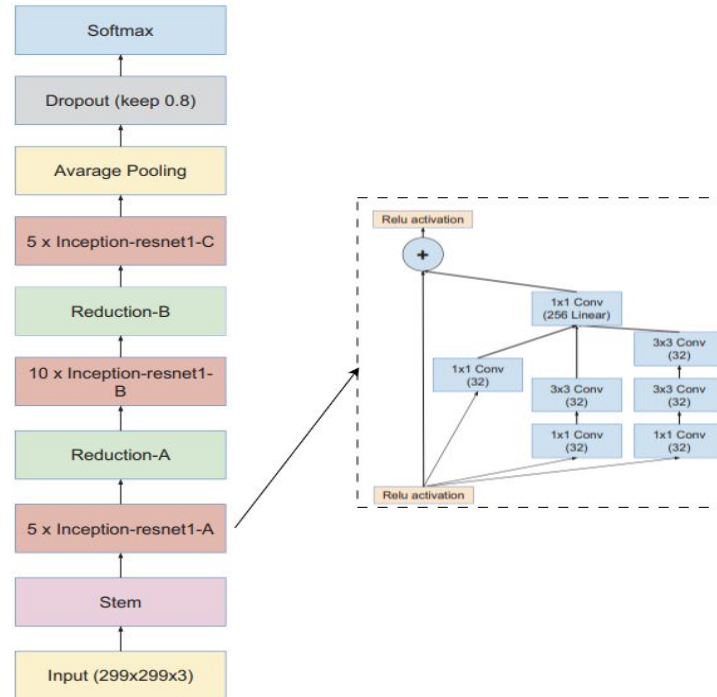


Fonte: Huang et al.

Materiais e métodos

Arquiteturas

- InceptionResNetV2
 - 164 camadas



Fonte: Adaptado de Szegedy et al.

Materiais e métodos

Métricas de avaliação

$$\text{Acurácia} = \frac{\text{Predições corretas}}{\text{Todas as predições}}$$

De todas as classificações, quantos % o modelo classificou corretamente

Materiais e métodos

Métricas de avaliação

$$\text{Precisão} = \frac{VP}{VP + FP}$$

De todas classificações positivas, que o modelo classificou de uma classe, quantas estão corretas

Materiais e métodos

Métricas de avaliação

$$Recall = \frac{VP}{VP + FN}$$

De todas classificações de uma classe, quantas
estão corretas

Materiais e métodos

Métricas de avaliação

$$F1\text{-Score} = 2 \times \frac{\text{Precisão} \times \text{Recall}}{\text{Precisão} + \text{Recall}}$$

Média harmônica entre precisão e *recall*

Resultados e Discussão

- Validação cruzada estratificada de 10 dobras para os pesos ImageNet e RadImageNet
- Parâmetros:
 - Treinamento realizado por 50 épocas
 - Todas as camadas da rede descongeladas
 - Taxa de aprendizado de 0,001

Resultados e Discussão

- Validação cruzada

DenseNet-121								
ImageNet					RadImageNet			
	A.	Pre.	Rec.	F1	A.	Pre.	Rec.	F1
Média	56%	56%	56%	54%	59%	60%	59%	57%
DP	5%	6%	6%	6%	7%	7%	7%	8%

InceptionResNetV2								
	A.	Pre.	Rec.	F1	A.	Pre.	Rec.	F1
Média	55%	55%	54%	54%	57%	57%	56%	54%
DP	8%	8%	8%	8%	5%	5%	5%	6%

Resultados e Discussão

- Teste t pareado

$$t = \frac{\bar{x}_d - \mu_0}{S_d / \sqrt{n}}$$

Considerando:

- \bar{x}_d : média das diferenças de cada par
- μ_0 : diferença esperada entre os dois grupos (zero)
- S_d : desvio padrão das diferenças
- n : número de pares

Resultados e Discussão

- Hipóteses tomadas para cada métrica:
 - Hipótese nula = Utilização dos pesos RadImageNet não impacta nos resultados, ou seja, as médias são iguais.
 - Hipótese alternativa = Utilização dos pesos RadImageNet melhora os resultados, ou seja, média RadImageNet maior que a média ImageNet.

Resultados e Discussão

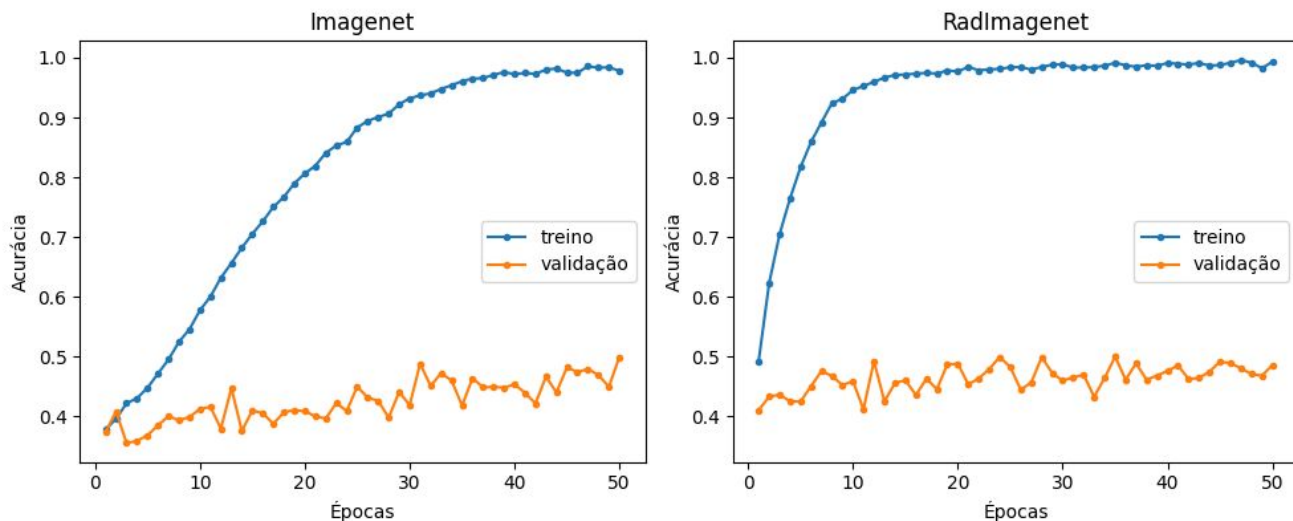
- Teste t pareado

DenseNet-121					InceptionResNetV2			
	A.	Pre.	Rec.	F1	A.	Pre.	Rec.	F1
t	2,15	1,75	2,26	1,95	0,89	0,88	0,99	0,34
p	0,03	0,057	0,025	0,041	0,2	0,2	0,17	0,37

Resultados e Discussão

- Curvas médias de acurácia por época

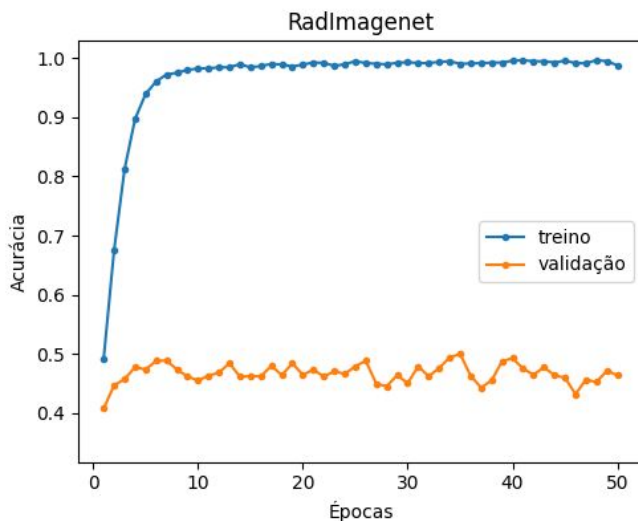

DenseNet-121



Resultados e Discussão

- Curvas médias de acurácia por época

InceptionResNetV2



Considerações Finais

- Utilização dos pesos médicos apresentaram melhoras estatisticamente significantes para a arquitetura DenseNet-121
- Pode trazer mais rapidez no treinamento

Conclusões

Trabalhos Futuros

- Testes para arquiteturas restantes (ResNet50 e InceptionV3)
- Aumentar número de épocas
- Avaliar outras técnicas de pré-processamento e aumento de dados como a apresentada por Chi et al

Obrigada!